

Whisper vs Swiss German: Improvement but Systematic Errors Persist

Sarruja Sabesan · Natalie Jakob

Course: Natural Language Processing

Lecturer: Mark Cieliebak

FS 2026

Research Question	Error Type Distribution	Ground Truth vs. Prediction Examples																							
Does Whisper improve on Swiss German and what errors remain?	Error Type-Distribution - Whisper v1 / v2 / v3 Substitutions Deletions Insertions 74.4% 11.7% 13.9% large-v1 Substitutions Deletions Insertions 74.5% 11.6% 13.9% large-v2 Substitutions Deletions Insertions 74.8% 11.9% 13.2% large-v3 Key Finding ~75% of errors are dialect → standard substitutions Semantically correct dialect→standard outputs are penalized as errors	<table><tr><th>Ground Truth</th><th>Whisper Output</th><th>Error Type</th><th>WER</th></tr><tr><td>und neue türen haben sich nicht geöffnet.</td><td>die neuen türen haben sich nicht geöffnet.</td><td>Dialect → Standard</td><td>0.29</td></tr><tr><td>der gemeinderat nimmt es auch als postulat entgegen.</td><td>der gemeintod nimmt sauers postulat entgegen.</td><td>Phonetic</td><td>0.5</td></tr><tr><td>Ein 30%iges Wachstum im Jahr 2018 gegenüber dem Schnitt 2014-2017 ist inakzeptabel.</td><td>Ein 30% Wachstum im Jahr 2018 gegenüber dem Schnitt von 2014 bis 2017 ist inakzeptabel.</td><td>Formatting (numbers / morphology)</td><td>0.4</td></tr><tr><td>Ich bin der Meinung, dass ihr noch nicht alle Sparmöglichkeiten ausgeschöpft habt.</td><td>Ich bin der Meinung, dass Sie noch nicht alle Sparmöglichkeiten ausgeschöpft haben.</td><td>Semantic (formal vs informal)</td><td>0.17</td></tr></table>				Ground Truth	Whisper Output	Error Type	WER	und neue türen haben sich nicht geöffnet.	die neuen türen haben sich nicht geöffnet.	Dialect → Standard	0.29	der gemeinderat nimmt es auch als postulat entgegen.	der gemeintod nimmt sauers postulat entgegen.	Phonetic	0.5	Ein 30%iges Wachstum im Jahr 2018 gegenüber dem Schnitt 2014-2017 ist inakzeptabel.	Ein 30% Wachstum im Jahr 2018 gegenüber dem Schnitt von 2014 bis 2017 ist inakzeptabel.	Formatting (numbers / morphology)	0.4	Ich bin der Meinung, dass ihr noch nicht alle Sparmöglichkeiten ausgeschöpft habt.	Ich bin der Meinung, dass Sie noch nicht alle Sparmöglichkeiten ausgeschöpft haben.	Semantic (formal vs informal)	0.17
Ground Truth	Whisper Output	Error Type	WER																						
und neue türen haben sich nicht geöffnet.	die neuen türen haben sich nicht geöffnet.	Dialect → Standard	0.29																						
der gemeinderat nimmt es auch als postulat entgegen.	der gemeintod nimmt sauers postulat entgegen.	Phonetic	0.5																						
Ein 30%iges Wachstum im Jahr 2018 gegenüber dem Schnitt 2014-2017 ist inakzeptabel.	Ein 30% Wachstum im Jahr 2018 gegenüber dem Schnitt von 2014 bis 2017 ist inakzeptabel.	Formatting (numbers / morphology)	0.4																						
Ich bin der Meinung, dass ihr noch nicht alle Sparmöglichkeiten ausgeschöpft habt.	Ich bin der Meinung, dass Sie noch nicht alle Sparmöglichkeiten ausgeschöpft haben.	Semantic (formal vs informal)	0.17																						
WER vs CER	Error Category Overview	Linguistic Insights																							
Whisper v1 WER 29.4% CER 14.3% Whisper v2 WER 25.6% CER 12.5% Whisper v3 WER 25.0% CER 12.1% Error Rate (%) WER vs CER - Whisper v1 / v2 / v3 WER CER large-v1 large-v2 large-v3	Top Error Tokens by Type Substitutions dies→das 266 diese→die 306 den→der 241 die 396 prozent 119 das 132 Deletions die 368 prozent 139 das 108 die 408 prozent 125 das 108 Insertions die 436 der 326 von 301 die 413 der 294 von 297	Whisper systematically maps Swiss German to Standard German rather than transcribing dialect verbatim (~75% of errors are dialect→standard substitutions). Grammatical changes such as tense shifts (e.g. "wurde" → "ist") or pronoun changes (e.g. "ihr" → "Sie") increase WER even when meaning is preserved. Number normalization (e.g. "zwanzig" → "20") is counted as an error by WER despite being semantically correct. Error patterns remain consistent across v1, v2 and v3 — model improvements reduce error frequency, not error type.																							

Consistent WER Improvement

- Largest gain between v1 and v2 (3.8%)
- Marginal improvement v2→v3 on Swiss German.

Error Pattern

- ~75% of errors are dialect → standard substitutions
- Error patterns remain consistent across models

WER Underestimates True Quality

- WER penalizes semantically correct outputs