

Whisper vs Swiss German: Improvement but Systematic Errors Persist

Sarruja Sabesan · Natalie Jakob | Course: Natural Language Processing | Lecturer: Mark Cieliebak | FS 2026

Research Question

Does *Whisper* improve on Swiss German and what errors remain?

Background

- **Goal**
 - Swiss German has no standardized spelling → challenging for ASR
 - We evaluate Whisper (v1–v3) on dialect speech
- **Dataset**
 - STT4SG-350 (~24k data, 7 dialects)
- **Models**
 - Whisper large (v1, v2, v3) – no fine-tuning
- **Metrics**
 - WER (primary), CER (secondary)
- **Analysis**
 - substitution, deletion, insertion errors


WER vs CER

Whisper v1
WER 29.4%
CER 14.3%


Whisper v2
WER 25.6%
CER 12.5%

Whisper v3
WER 25.0%
CER 12.1%

WER vs CER – Whisper v1 / v2 / v3




Error Type Distribution



Key Finding
~75% of errors are dialect → standard substitutions

Error Category Overview



Ground Truth vs. Prediction Examples

Ground Truth	Whisper Output	Error Type	WER
und neue türen haben sich nicht geöffnet.	die neuen türen haben sich nicht geöffnet.	Dialect → Standard	0.29
der gemeinderat nimmt es auch als postulat entgegen.	der gemeintod nimmt sauers postulat entgegen.	Phonetic	0.5
Ein 30%iges Wachstum im Jahr 2018 gegenüber dem Schnitt 2014-2017 ist inakzeptabel.	Ein 30% Wachstum im Jahr 2018 gegenüber dem Schnitt von 2014 bis 2017 ist inakzeptabel.	Formatting (numbers / morphology)	0.4
Ich bin der Meinung, dass ihr noch nicht alle Sparmöglichkeiten ausgeschöpft habt.	Ich bin der Meinung, dass Sie noch nicht alle Sparmöglichkeiten ausgeschöpft haben.	Semantic (formal vs informal)	0.17

Linguistic Insights

- Whisper maps Swiss German to Standard German rather than transcribing dialect verbatim.
- Many errors are dialect → standard substitutions (~75%), indicating systematic normalization rather than random mistakes.
- Grammatical changes (e.g., tense shifts or pronoun changes) increase WER even when meaning is preserved.
- Error patterns are consistent across v1, v2 and v3 — improvements reduce error frequency, not error type.

KEY INSIGHTS

Consistent WER Improvement

- Largest gain between v1 and v2 (3.8%)
- Marginal improvement v2→v3 on Swiss German.

Error Pattern

- ~75% of errors are dialect → standard substitutions
- Error patterns remain consistent across models

WER Underestimates True Quality

- WER penalizes semantically correct outputs